


AI Researcher

Han-Jun Choi Portfolio

최한준


010-8704-4603

hanjun_c@naver.com



Web Portfolio

<https://gkswns95.github.io/poftfolio/>



1. Work Experience

2. KEY PAPER #1 소개

3. KEY PAPER #2 소개

4. KEY PAPER #3 소개

Work Experience: Project # 1

회사명: 한국전자기술연구원(KETI)

부서: AI기반모델연구센터

직급: 연구원

- **프로젝트명:** [Social VLA Modeling] 인간-로봇 간 몰입형 대화를 위한 음성·모션 생성 모델 개발

- **수행 기간:** 2026.05 ~

- **기술 스택:** VLA, MLLM, VAE, Diffusion, ROS2, Docker, Webots

- **참여 인력:** 1 / 2

- **프로젝트 개요:**

사용자의 발화 의도와 대화 문맥을 이해하고 이에 적절한 음성 및 모션을 생성할 수 있는 휴머노이드 로봇 개발 프로젝트에서 연구 기획과 VLA 기반 로봇 제어 프레임워크 설계를 담당하고 있습니다. 특히, ROS2 기반 휴머노이드 로봇과 추론부 모델 간의 실시간 통신 환경 구축을 목표로 End-to-End 시스템을 개발하고 있습니다.

- **수행 내용:**

- **Vector Quantization:** 연속적인 음성·모션 데이터를 MLLM이 처리 가능한 형태로 변환하기 위해 VAE 기반 벡터 양자화
- **Cross-modal Alignment:** 음성·모션 토큰이 의미 있는 표현을 학습할 수 있도록 텍스트-음성·모션 간 정렬 학습 수행
- **Model-Robot Integration:** ROS2 기반의 추론 모델-로봇 간 양방향 통신이 가능한 End-to-End 프레임워크 구축
- **Synthetic Data Generation:** LLM API 기반 멀티모달 대화 시나리오 생성 및 학습 데이터셋 구축

- **기여도 및 성과:**

- VLA 모델링 및 로봇 연동 프레임워크 설계 주도
- Webots 기반 시뮬레이션 검증 환경 구축
- ROS2 기반 실시간 추론-제어 시스템 개발 진행 중

Work Experience: Project # 2

회사명: 한국전자기술연구원(KETI)

부서: AI기반모델연구센터

직급: 연구원

- **프로젝트명:** [Multimodal Modeling] 사용자 감정 인식을 위한 음성·영상·텍스트 기반 멀티모달 융합 모델 개발
- **수행 기간:** 2024.01 ~ 2026.05
- **기술 스택:** Multimodal Transformer, Knowledge Distillation, Curriculum Learning, Noise-resistant Multimodal Fusion, Sentiment Analysis, Emotion Recognition
- **참여 인력:** 1 / 4
- **프로젝트 개요:**

대화 중 사용자의 감정을 포착함으로써 발화 의도와 맥락을 보다 정확하게 이해할 수 있는 챗봇 개발 프로젝트에서 멀티모달 융합 모델링을 담당했습니다. 특히 실제 데이터 수집 환경에서 발생하는 노이즈 및 결측 데이터에 강건한 모델 설계에 집중했습니다.

Work Experience: Project # 2

회사명: 한국전자기술연구원(KETI)

부서: AI기반모델연구센터

직급: 연구원

- **프로젝트명:** [Multimodal Modeling] 사용자 감정 인식을 위한 음성·영상·텍스트 기반 멀티모달 융합 모델 개발
- **수행 내용:**
 - **Noise-resistant Learning:** 추론 환경에서 발생하는 노이즈 및 결측 데이터로 인한 성능 저하 문제 개선
 - **Confidence Estimation:** 입력 데이터의 정보 손실량 추정을 위한 신뢰도 기반 추론 패러다임 제안
 - **Pseudo Labeling:** 신뢰도 학습을 위한 학습 데이터셋 구축 프레임워크 설계
 - **Reconstruction:** 신뢰도 기반 손실 정보 복원 메커니즘 설계
 - **Training Strategy:** 멀티 태스크 학습 과정에서 발생하는 가중치 충돌 문제 완화를 위한 학습 전략 설계
 - **Text-centric Fusion:** 텍스트 중심의 멀티모달 융합 모델링
- **기여도 및 성과:**
 - 연구 아이디어 제안, 모델 설계 및 논문 작성 주도
 - EMNLP 2026 제출 (제1저자, Meta Review 완료)
 - SCI(E) 저널 논문 제출 (제2저자, IF 1.7, Q3)
 - KIBME 2025 논문 게재 (제1저자, 최우수논문상 수상)
 - HCLT 2024 논문 게재 및 구두 발표 (제1저자)

Work Experience: Project # 3

회사명: 한국전자기술연구원(KETI)

부서: AI기반모델연구센터

직급: 연구원

- **프로젝트명:** [Multi-Object Trajectory Modeling] 다중 객체 환경에서의 궤적 예측 모델 개발
- **수행 기간:** 2024.01 ~ 2025.10
- **기술 스택:** Transformer, Set Transformer, Time-series Modeling, Multi-Object Modeling, Trajectory Prediction, Trajectory Imputation, Trajectory Tracking
- **참여 인력:** 1 / 7
- **프로젝트 개요:**

다중 객체가 상호작용하는 Multi-Object 환경에서 물리적으로 자연스러운 궤적을 예측하기 위한 Trajectory Prediction 모델 개발 프로젝트를 수행했습니다. 특히, 객체 간 상호작용과 운동학적 특성을 효과적으로 반영할 수 있는 궤적 모델링에 집중했습니다.

Work Experience: Project # 3

회사명: 한국전자기술연구원(KETI)

부서: AI기반모델연구센터

직급: 연구원

- **프로젝트명:** [Multi-Object Trajectory Modeling] 다중 객체 환경에서의 궤적 예측 모델 개발
- **수행 내용:**
 - **Research:** Multi-Object Tracking, Imputation 연구 동향 파악
 - **Trajectory Imputation:** 카메라 가림 및 센서 오류로 인해 발생한 결측 궤적 복원을 위한 궤적 보간 모델 제안
 - **Multi-Agent Interaction Modeling:** 객체 간 복잡한 상호작용 정보 인코딩을 위한 Permutation Equivariant & Invariant 임베딩 제안
 - **Physics-based Modeling:** 물리적으로 자연스러운 궤적 예측을 위한 위치·속도·가속도 기반 궤적 예측 메커니즘 제안
 - **Hybrid Ensemble:** 예측 구간 및 길이에 따른 최적의 예측 결과를 위한 동적 앙상블 모듈 제안
- **기여도 및 성과:**
 - 연구 아이디어 제안, 모델 설계 및 논문 작성 주도
 - ECML-PKDD 2025 논문 게재 (제1저자, BK21 Top-tier, Oral)
 - CIKM 2025 논문 게재 (제3저자, BK212 Top-tier, Poster)

1. Work Experience

2. KEY PAPER #1 소개

3. KEY PAPER #2 소개

4. KEY PAPER #3 소개

KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang
[Under-review]

[연구 요약]

연구 목표

- 데이터의 노이즈·결측 문제로 인한 감정 인식 성능 저하 문제 해결
- **불완전 데이터 환경에 강건한 멀티모달 융합 모델 설계**

제안 방법


- 신뢰도 기반 멀티모달 융합 프레임워크 제안
- 결측 텍스트 내 남은 감정 관련 정보량 추정 방식 제안
- 신뢰도 추정 네트워크 학습을 위한 Pseudo-labeling 기법
- 멀티태스크 학습 안정화를 위한 최적화 기법 설계

실험 결과


- 벤치마크 데이터셋(MOSI, MOSEI, SIMS)에 대한 성능 평가
- 다양한 결측 비율(0~100%)에서의 성능 변화 분석
- 예측 정확도(Acc) 약 6.68% 향상, 오차(MAE) 약 6.37% 감소
- **실세계 데이터 환경에서 신뢰도 있는 감정 예측이 가능함을 입증**

성과


- EMNLP 2026 제출(국제 최우수 학술대회)
- 1차 심사 결과: 2026년 5월 예정



Method	MOSI							
	Acc-7	Acc-5	Non0 Acc	F1	Has0 Acc	F1	MAE	Corr
MISA	29.03	31.61	68.77	68.67	67.94	67.72	1.1637	47.57
Self-MM	30.38	33.69	68.83	68.63	68.65	69.34	1.1843	47.25
MMIM	30.67	34.31	70.19	69.87	69.59	69.15	1.1649	49.01
CENet	29.49	32.90	69.88	69.94	69.43	69.39	1.1801	48.24
TETFN	29.86	32.56	70.62	70.67	69.85	69.79	1.1327	49.16
TFR-Net	28.22	30.31	70.88	70.73	70.18	69.93	1.1454	50.05
ALMT	29.57	32.05	71.51	71.48	70.52	70.39	1.1671	47.57
LNLN	31.36	34.43	70.00	69.99	69.51	69.41	1.1450	48.08
P-RMF	28.91	31.24	69.91	69.57	69.28	68.84	1.1302	50.07
TF-Mamba	28.85	31.46	71.05	71.11	70.73	70.69	1.1228	51.97
TCMR-MRSC	30.39	33.36	70.84	70.95	69.81	69.82	1.1061	50.86
TCMR-LDSC	31.63	35.38	70.61	70.55	69.83	69.58	1.1322	49.07
TCMR-TPSC	32.80	36.73	72.01	71.67	70.93	70.49	1.0721	52.28



Example text: "I really love this movie." [M]: missing token



	Key Semantic Cue "PRESENT"	Key Semantic Cue "MISSING"
Missing Rate "LOW"	"and he was still boring" LNLN: Negative ✓ TCMR: Negative ✓	"uh huh, how about the acting and the action was just so dull" LNLN: Positive ✗ TCMR: Negative ✓
Missing Rate "HIGH"	"and it's truly heartbreaking to see that contrasted with the state of things" LNLN: Positive ✗ TCMR: Negative ✓	"There're also two lord of the rings grads which I absolutely love" LNLN: Negative ✗ TCMR: Positive ✓

KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggill Joe, Saim Shin, Jin Yea Jang

[Under-review]

[연구 배경]

멀티모달 감정 분석 연구 동향

- 멀티모달 감정 분석: 텍스트·오디오·영상을 기반 사용자 감정 예측
- 연구 동향: 텍스트 중심의 멀티모달 융합 방법론 연구 활발

현실 세계의 불완전 데이터 문제

- 데이터 취득 과정에서 다양한 이유로 노이즈·결측치 포함
- 감정 인식 모델의 성능 저하를 유발하는 요인으로 작용

➤ 텍스트 중심의 융합 프레임워크에서는 더욱 큰 성능 저하 발생

기존 연구의 한계점

- 기존 연구: 손실된 텍스트의 의미론적 정보 복원 방법 제안
 - 결측 비율을 정보 손실량으로 정의하고 이를 복원 가중치로 활용
 - 보조 모달리티(오디오, 영상)으로부터 손실된 감정 정보 복원
- 한계점: 단순 결측 비율은 실질적인 정보 손실량을 반영하지 못할 수도 있음
 - Case 1) 감정 단서 'Love' 결측 => 결측 비율이 낮음에도 정보량 과대 평가
 - Case 2) 감정 단서 'Love' 보존 => 감정 예측에 충분한 단서가 있음에도 과소 평가

➤ 단순 결측 비율이 아닌 감정 단서 결측 정도에 따른 정보량 추정 기법 설계의 필요성



Example text: “I really love this movie.” [M]: missing token

Case 1) Only one key semantic cue is missing

I really [M] this movie

Text Completeness



Case 2) Only one key semantic cue remains

[M] [M] love [M] [M]

Text Completeness



KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang

[Under-review]

[제안 방법]

Text Completeness Estimation: 텍스트 완전성 추정

- 텍스트의 의미론적 완전성 추정 네트워크 설계
- Pseudo-labeling을 통한 학습 레이블 생성 기법 제안


➤ **불완전 텍스트 입력에 대한 신뢰도로 활용**

Proxy Feature Generation: 대체 표현 생성

- 음성·영상 모달리티로부터 손실된 텍스트 정보 복원
 - Gate network 구조의 복원 네트워크 설계
- **텍스트 복원에 불필요한 정보 제거를 통한 복원 성능 향상**

Text Semantic Reconstruction: 손실된 의미론적 정보 복원

- 불완전 텍스트와 생성된 텍스트 표현을 결합하여 복원
 - 추정된 텍스트의 완전성 정보를 가중치로 하여 가중합
- **불완전 데이터 환경에서도 강건한 멀티모달 융합 가능**



KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis


Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang

[Under-review]


Completeness Label Generation

✓ 텍스트 완전성 추정 네트워크 학습을 위한 학습 레이블 생성 기법 제안

- Target Probability-based Semantic Completeness (TPSC): **정답 클래스에 할당된 확률** 기반 정답 레이블 생성
- Lexicon-Derived Semantic Completeness (LDSC): **어휘 사전으로부터 얻은 감정 스코어** 기반 정답 레이블 생성



(a) TPSC



(b) LDSC

KEY PAPER #1


TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggill Joe, Saim Shin, Jin Yea Jang


[Under-review]

Target Probability-based Semantic Completeness (TPSC)

1. Training Classifier: 결측이 없는 완전한 데이터를 입력으로 분류 모델 학습
 2. Pseudo-labeling: 결측 데이터를 입력으로 추론했을 때의 정답 클래스 예측 확률을 완전성으로 정의
- 가설: 감정 관련 단서가 보존된 경우 예측 확률의 안정적 유지, 감정 단서가 결측된 경우 해당 확률의 현저한 감소



(a) TPSC



(b) LDSC

KEY PAPER #1


TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang

[Under-review]

Lexicon-Derived Semantic Completeness (LDSC)

1. Compute sentiment strength: 감정 사전으로부터 추출한 각 토큰의 감성 스코어를 기반으로 전체 문장의 감성 강도 산출
 2. Define lexicon-based completeness: 두 감성 강도의 비율을 결측 문장의 완전성으로 정의
- 가설: 사전에 정의된 감성 단어의 결측 유무에 따른 감성 정보 보존 정도의 차이



Alternative Optimization Strategy (AOS)

- Multi-task objectives: $\mathcal{L}_{\text{comp}}$ (완전성 학습) + $\mathcal{L}_{\text{task}}$ (감정 예측)

$$\mathcal{L}_{\text{total}} = \alpha \mathcal{L}_{\text{comp}} + \beta \mathcal{L}_{\text{rec}}^t + \gamma \mathcal{L}_{\text{rec}}^{m'} + \sigma \mathcal{L}_{\text{task}}.$$

- Gradient Conflict 문제 발생: E2E 학습 시 $\mathcal{L}_{\text{comp}}$ 학습 무시 현상

- Objective decomposition: 각 목적에 따라 두 그룹으로 분리

$$\mathcal{L}_{\text{comp}}, \quad \mathcal{L}_{\text{other}} = \beta \mathcal{L}_{\text{rec}}^t + \gamma \mathcal{L}_{\text{rec}}^{m'} + \sigma \mathcal{L}_{\text{task}}.$$

- Two-stage learning: 두 그룹의 손실 함수를 번갈아가며 최적화

- Stage 1: 완전성 추정 네트워크 학습
- Stage 2: 태스크 관련 네트워크 학습

Algorithm 1 Alternative Optimization Strategy

Input: dataset $\mathcal{D}$, epochs E , batch size B , weights $\alpha, \beta, \gamma, \sigma$.

Params: $\Theta^{\text{comp}} = \theta^{\text{comp}} \cup \theta^{\text{bert}}$, Θ^{other} for the remaining modules including θ^{bert} .

Opt: Opt_{comp} , $\text{Opt}_{\text{other}}$.

1: **for** $e = 1$ to E **do**

Phase 1: optimize Θ^{comp} to minimize $\mathcal{L}_{\text{comp}}$

2: **for** mini-batch $\mathcal{B} \subset \mathcal{D}$, $|\mathcal{B}| = B$ **do**

3: $\mathcal{L}_{\text{comp}} \leftarrow \text{LossComp}(\mathcal{B}; \Theta^{\text{comp}})$

4: $\mathcal{L}_{\text{comp}} \leftarrow \alpha \mathcal{L}_{\text{conf}}$

5: $\text{Opt}_{\text{comp}}.\text{step}(\nabla_{\Theta^{\text{comp}}} \mathcal{L}_{\text{comp}})$

6: **end for**

Phase 2: optimize Θ^{other} to minimize $\mathcal{L}_{\text{other}}$

7: **for** mini-batch $\mathcal{B} \subset \mathcal{D}$, $|\mathcal{B}| = B$ **do**

8: $\mathcal{L}_{\text{task}} \leftarrow \text{LossTask}(\mathcal{B}; \Theta^{\text{other}})$

9: $\mathcal{L}_{\text{rec}}^t \leftarrow \text{LossRecText}(\mathcal{B}; \Theta^{\text{other}})$

10: $\mathcal{L}_{\text{rec}}^{m'} \leftarrow \text{LossRecAux}(\mathcal{B}; \Theta^{\text{other}})$

11: $\mathcal{L}_{\text{other}} \leftarrow \beta \mathcal{L}_{\text{rec}}^t + \gamma \mathcal{L}_{\text{rec}}^{m'} + \sigma \mathcal{L}_{\text{task}}$

12: $\text{Opt}_{\text{other}}.\text{step}(\nabla_{\Theta^{\text{other}}} \mathcal{L}_{\text{other}})$

13: **end for**

14: **end for**




Table 8: Gradient conflict rate (GCR) analysis measured during training. F50/L50 denote the first and last 50% of training epochs, respectively.

Method	GCR (%) ↓			$\mathcal{L}_{\text{comp}} \downarrow$
	All	F50	L50	
E2E	51.27	51.16	54.36	0.1634
GradNorm	54.84	56.55	53.16	0.1294
PCGrad	52.33	57.43	48.70	0.0340
AOS	48.47	53.67	43.33	0.0055

KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggill Joe, Saim Shin, Jin Yea Jang
[Under-review]

[실험 결과]

데이터셋

- ✓ 서로 다른 세 개의 벤치마크 감성 데이터셋 (MOSI, MOSEI, SIMS)

정량적 실험 결과 비교

- ✓ SOTA 기록 달성: 모든 데이터셋에서 일관되게 최고 성능 달성
 - 감정 예측 정확도: 기존 SOTA 대비 Acc-5 6.68% 향상
 - 감성 예측 오차: 기존 SOTA 대비 MAE 약 6.37% 감소
- ✓ Pseudo-labeling 효과성 검증: 서로 다른 완전성 측정법과의 비교 실험
 - MRSC: 결측 비율을 기준으로 완전성 측정
 - TPSC: 정답 클래스 확률을 기준으로 완전성 측정
 - LDSC: 감성 단어 사전을 기준으로 완전성 측정
 - ‘TCMR-’ 중 TPSC가 가장 높은 성능 기록
- ✓ 노이즈에 대한 강건성 검증: 다양한 결측 비율에 따른 성능 변화 비교 실험
 - 기존 복원 방법론 대비 가장 안정적인 성능을 유지하는 것을 확인

Table 1: Comparison of the overall performance on MOSI and MOSEI datasets.

Method	MOSI								MOSEI							
	Acc-7	Acc-5	Non0	Acc / F1	Has0	Acc / F1	MAE	Corr	Acc-7	Acc-5	Non0	Acc / F1	Has0	Acc / F1	MAE	Corr
MISA	29.03	31.61	68.77	68.67	67.94	67.72	1.1637	47.57	43.89	44.43	72.22	68.21	74.16	71.24	0.7346	43.57
Self-MM	30.38	33.69	68.83	68.63	68.65	69.34	1.1843	47.25	46.45	47.36	73.02	71.43	72.66	71.82	0.6818	53.68
MMIM	30.67	34.31	70.19	69.87	69.59	69.15	1.1649	49.01	44.89	45.42	74.29	73.19	73.46	73.19	0.7032	52.75
CENet	29.49	32.90	69.88	69.94	69.43	69.39	1.1801	48.24	47.36	48.24	77.01	77.26	75.96	76.23	0.6622	58.24
TETFN	29.86	32.56	70.62	70.67	69.85	69.79	1.1327	49.16	46.78	47.83	77.87	77.45	76.11	76.37	0.6741	58.31
TFR-Net	28.22	30.31	70.88	70.73	70.18	69.93	1.1454	50.05	46.08	46.47	75.46	74.10	74.18	73.61	0.6784	56.24
ALMT	29.57	32.05	71.51	71.48	70.52	70.39	1.1671	47.57	46.66	47.37	76.83	76.41	74.47	74.84	0.6749	56.45
LNLN	31.36	34.43	70.00	69.99	69.51	69.41	1.1450	48.08	46.36	47.14	77.79	77.27	76.43	76.58	0.6698	58.17
P-RMF	28.91	31.24	69.91	69.57	69.28	68.84	1.1302	50.07	47.01	47.82	78.07	77.76	77.18	76.91	0.6667	58.45
TF-Mamba	28.85	31.46	71.05	71.11	70.73	70.69	1.1228	51.97	45.11	46.09	76.11	76.17	72.54	73.49	0.6891	57.51
TCMR-MRSC	30.39	33.36	70.84	70.95	69.81	69.82	1.1061	50.86	46.61	47.46	77.65	76.74	76.91	76.64	0.6673	58.46
TCMR-LDSC	31.63	35.38	70.61	70.55	69.83	69.58	1.1322	49.07	47.13	47.87	77.52	76.97	76.16	76.29	0.6641	58.51
TCMR-TPSC	32.80	36.73	72.01	71.67	70.93	70.49	1.0721	52.28	47.27	48.16	77.99	76.99	77.59	77.21	0.6614	58.63

Method	Acc-5	Acc-3	Acc-2	F1	MAE	Corr
MISA	32.97	56.05	71.25	66.95	0.5731	0.319
Self-MM	33.57	55.82	69.02	68.38	0.5243	0.363
MMIM	30.33	55.04	69.46	66.74	0.5629	0.301
CENet	21.61	53.48	69.23	56.97	0.6304	0.014
TETFN	34.91	56.01	70.85	69.17	0.5439	0.342
TFR-Net	27.21	54.26	69.37	56.82	0.6258	0.091
ALMT	30.99	53.23	70.65	67.34	0.5445	0.311
LNLN	32.17	56.77	71.51	69.21	0.5423	0.345
P-RMF	32.72	57.30	70.58	70.36	0.5432	0.361
TF-Mamba	33.05	55.18	69.88	69.24	0.5235	0.359
TCMR-MRSC	33.27	55.46	70.03	68.76	0.5446	0.341
TCMR-TPSC	30.99	57.31	72.88	68.87	0.5222	0.374

Table 2: Comparison of the overall performance on the SIMS dataset. Note: TCMR-LDSC is excluded since it is based on an English sentiment lexicon.




Figure 3: Performance curves under various missing rates. (a)–(c): Accuracy on MOSI (Acc-7), MOSEI (Has0 Acc), and SIMS (Acc-2). (d)–(f): MAE on MOSI, MOSEI, and SIMS.

KEY PAPER #1

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang

[Under-review]


Comprehensive Analysis

(a) Sentiment token sensitivity



(b) Comparison of reconstruction quality

	Key Semantic Cue “PRESENT”	Key Semantic Cue “MISSING”
Missing Rate “LOW”	“and he was still boring” LNLN: Negative ✓ TCMR: Negative ✓	“uh huh, how about the acting and the action was just so dull” LNLN: Positive ✗ TCMR: Negative ✓
Missing Rate “HIGH”	“and it’s truly heartbreaking to see that contrasted with the state of things” LNLN: Positive ✗ TCMR: Negative ✓	“There’re also two lord of the rings grads which I absolutely love” LNLN: Negative ✗ TCMR: Positive ✓



✓ 기존 SOTA와의 비교 실험: 감정 단서가 결측된 상황에서도 정확한 복원이 가능함을 입증

✓ Pseudo-labeling 검증: 감정에 연관된 단어에 높은 스코어 할당

TCMR: Semantic-aware Text Completeness for Missing Semantic Reconstruction in Incomplete Multimodal Sentiment Analysis

Han-Jun Choi, Byunggil Joe, Saim Shin, Jin Yea Jang
[Under-review]

Comprehensive Analysis

Table 7: Qualitative comparison of completeness labels. Each case shows how MRSC, LDSC, and TPSC assign completeness labels depending on whether sentiment-related tokens are missing. In the TPSC column, the value in parentheses denotes $P(y_{sp} \mid \text{complete})$, while the value above it denotes $P(y_{sp} \mid \text{incomplete})$. ✓ and ✗ indicate correct and incorrect completeness estimation, respectively.

Case	Complete Text	Incomplete Text	MRSC	LDSC	TPSC
1	I was happy to see it	I [UNK] happy to see it	0.8333 ✓	0.9888 ✓	0.9526 (0.9580) ✓
2	The soundtrack is good its really good some really great songs	[UNK] soundtrack [UNK] [UNK] [UNK] really [UNK] [UNK] [UNK] [UNK] [UNK]	0.1818 ✓	0.0044 ✓	0.3077 (0.9665) ✓
3	But it was really really awesome	but it was [UNK] [UNK] [UNK]	0.5000 ✗	0.0112 ✓	0.3179 (0.9680) ✓
4	Kids are gonna love the film	[UNK] [UNK] [UNK] love the [UNK]	0.3333 ✗	0.9808 ✓	0.8638 (0.9571) ✓
5	I will admit I'm a big Johnny Depp fan	I will [UNK] I'm [UNK] big Johnny Depp fan	0.7931 ✓	0.0690 ✗	0.9160 (0.9491) ✓
6	and you're better off saving your money uh and maybe renting it when it comes out on uh video so	and [UNK] better [UNK] saving [UNK] money [UNK] [UNK] maybe renting it when it [UNK] out [UNK] uh [UNK] [UNK]	0.5921 ✓	0.9928 ✗	0.4608 (0.6153) ✓
7	I really dig this movie	I [UNK] [UNK] this [UNK]	0.4000 ✗	0.5000 ✗	0.1006 (0.9477) ✓

✓ 서로 다른 세 방법론 중 감정 스코어를 가장 정확하게 할당

(c) Qualitative comparison of completeness label

1. Work Experience

2. KEY PAPER #1 소개

3. KEY PAPER #2 소개

4. KEY PAPER #3 소개

KEY PAPER #2

Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko
[ECML PKDD] · 2025년 6월 20일

[연구 요약]

연구 목표

- 다중 객체 궤적 데이터의 결측치로 인한 분석 성능 저하 문제 해결
- 생체역학적 제약을 반영한 결측 궤적 보간 프레임워크 설계

제안 방법

- 다중 객체간 복잡한 상호작용 모델링
- 궤적 데이터의 순열 동변성을 고려한 임베딩 제안
- 위치·속도·가속도간 물리적 관계식 기반 궤적 예측 모듈 구현
- Soft Voting 기반 동적 융합 모듈 설계

실험 결과

- 팀 스포츠(축구, 농구, 미식축구) 데이터셋에 대한 성능 평가
- 서로 다른 세 가지 결측 시나리오에 따른 성능 변화 분석
- State-of-the-art 성능 달성
- 위치 오차 최대 37% 감소, 궤적 현실성 지표 약 36.7% 향상
- 현실 객체 움직임과 매우 유사한 궤적을 생성할 수 있음을 입증

성과

- ECML PKDD 2025 게재(국제 우수 학술대회)






Table 2: Performance of imputation methods on different datasets and scenarios.

Scenario	Metric	Method									
		LI	CS	BRITS	NAOMI	NRTSI	CSDI	GI	IF	IP	MIDAS
Soccer											
Uniform	PE	3.8406	2.2085	7.4859	4.5343	3.1791	3.4295	4.6511	2.0898	1.4563	1.3205
	SCE	0.1299	0.0867	3.9089	3.9793	0.0854	0.1586	0.1191	0.0815	0.1488	0.0516
Agent-wise	PE	5.0752	11.4647	5.7266	—	—	4.0279	5.6011	2.5798	2.0755	1.9832
	SCE	0.1631	0.2939	2.9627	—	—	0.1305	0.1508	0.0976	0.1057	0.0535
Camera	PE	3.1083	1.9209	7.4208	—	—	3.5181	3.6512	2.2151	1.4879	1.2296
	SCE	0.0993	0.0547	4.1967	—	—	0.2132	0.0934	0.3149	0.1554	0.0374
Basketball											
Uniform	PE	3.3481	2.3114	2.9085	1.5254	2.5291	2.2558	2.8305	1.3622	0.9801	0.9727
	SCE	0.1483	0.1025	1.0521	0.3230	0.0734	0.0631	0.1066	0.0531	0.0432	0.0438
Agent-wise	PE	4.4992	10.3857	2.4238	—	—	2.3471	2.5859	1.3345	1.3832	1.3862
	SCE	0.1787	0.2715	0.5397	—	—	0.0563	0.0700	0.0485	0.0373	0.0381
American Football											
Uniform	PE	0.8897	0.7448	1.7990	0.9692	0.5158	0.5558	0.8899	0.3673	0.2073	0.1542
	SCE	1.1063	0.9463	10.9459	2.3112	0.2989	0.4905	1.1023	0.2858	0.1990	0.1126
Agent-wise	PE	1.5128	1.2041	1.7527	—	—	0.6182	1.5128	0.3944	0.2383	0.2104
	SCE	1.0641	0.5306	10.6807	—	—	0.4288	1.0631	0.1869	0.1180	0.0967



KEY PAPER #2

Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

[연구 배경]

스포츠 경기 데이터의 결측 궤적 문제

- Player-tracking data는 주로 GPS, Vision 기술로 취득
- 센서 오류, 객체 인식 실패 등으로 인한 결측 궤적 발생
- 일부 궤적이 없는 데이터로는 downstream task 수행 불가

➤ 결측된 궤적을 실제와 유사한 값으로 보간하는 작업 필수

기존 연구의 한계점



1. 비현실적인 궤적 예측 문제

- 현실 궤적의 생체역학적 제약(예: 속도, 가속도 등) 고려 부족
- 실제와 다른 부자연스럽고 비현실적인 궤적을 생성하는 결과 초래

2. 집합 데이터의 순열 동변성 고려 부족

- 취득된 데이터의 선수 순서가 고정되어 있지 않음
예시) Seq 1: [A선수, B선수, ...], Seq 2: [B선수, A선수, ...]
- 모든 입력 순서를 학습해야 할 경우 => 학습 복잡도 급격히 증가
예시) 축구의 경우 최대 22! 경우의 수만큼 학습 필요

➤ 입력 순서에 관계없이 일관된 출력 보장하며 생체역학적
으로 현실적인 궤적을 예측할 수 있는 모델 설계 필요



(a) Full-pitch view along with camera coverage

(b) Close-up view

Fig. 1: Example of imputing unobserved player trajectories from tracking data

KEY PAPER #2

Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

[제안 방법]

Core neural network: 신경망 기반 궤적 보간 모델 (1차 궤적 예측)


- SetTransformer 인코더를 통해 선수 간 동적 상호작용 인코딩
- Bi-LSTM 기반 디코더를 통해 시간 흐름을 반영한 궤적 예측
- 위치·속도·가속도를 동시에 예측하는 초기 예측 수행

Derivative accumulation: 속도·가속도 기반 궤적 예측 (2차 궤적 예측)

- 초기 예측의 변동성(fluctuation) 문제를 완화하기 위해 도입
- 위치·속도·가속도 간 물리적 관계를 반영한 추가 예측 수행
- 물리적 제약을 반영함으로써 생체역학적으로 자연스러운 궤적 생성

Weighted ensemble: 예측 궤적 동적 융합 모델 (최종 궤적 예측)

- 각 예측의 상호보완적 특성을 극대화하기 위해 도입
- 1차·2차 예측을 동적으로 가중 결합
- 결측 구간의 길이 및 특성에 따라 안정적인 최종 궤적 생성



KEY PAPER #2


Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

Neural Network-Based Initial Prediction (IP)

- 순열 동변성을 보장하는 SetTransformer 인코더를 통한 선수 임베딩 생성
- 선수별로 시간적 패턴을 모델링하기 위한 Bi-LSTM 적용
- **각 시점에서 위치·속도·가속도를 동시에 예측**



KEY PAPER #2


Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

Derivative Accumulating Prediction (DAP)

- 위치·속도·가속도 간 물리적 관계식: $\mathbf{p}_{t+1}^k \approx \mathbf{p}_t^k + \mathbf{v}_{t+1}^k \Delta t \approx \mathbf{p}_t^k + (\mathbf{v}_t^k + \mathbf{a}_t^k \Delta t) \Delta t$
- 초기 예측 IP는 이러한 관계를 명시적으로 반영하지 않음
- 각 결측 구간 (t_s, t_e)에 대해, 양 끝 결측 구간 전후 위치부터 속도와 가속도 누적: $\hat{\mathbf{p}}_t^{k,f}$, $\hat{\mathbf{p}}_t^{k,b}$



KEY PAPER #2


Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

Dynamic Ensemble of Multiple Predictions

- IP와 DAP의 trade-off 문제
 - IP는 물리적 일관성을 보장하지 못하기 때문에 안정성이 떨어짐
 - DAP는 긴 결측 구간에 대해 오류 누적 문제가 발생하기 쉬움
- IP와 DAPs를 동적으로 융합할 수 있는 신경망 학습: $\hat{\mathbf{p}}_t^k = \lambda_t^{k,i} \hat{\mathbf{p}}_t^{k,i} + \lambda_t^{k,f} \hat{\mathbf{p}}_t^{k,f} + \lambda_t^{k,b} \hat{\mathbf{p}}_t^{k,b}$



KEY PAPER #2

Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

■ 데이터셋



- Soccer: 3 matches provided by Metrica Sports
- Basketball: 100 NBA matches provided by SportsVU
- American football: Preprocessed NFL sequences released with a Kaggle competition

Table 1: Details on the three sports datasets.


Split	Soccer		Basketball		A. Football	
	Matches	Frames	Matches	Frames	Matches	Frames
Training	2	65,014	70	1,621,835	—	425,000
Validation	0.5	20,104	10	216,118	—	52,150
Test	0.5	21,242	20	468,885	—	—

■ 결측 시나리오


- Uniform: Same missing interval for all players
- Agent-wise: Different missing intervals per player
- Camera: Players outside camera view are missing




Soccer




Basketball



Uniform missing



Agent-wise missing



Broadcasting camera

Trajectory Imputation in Multi-Agent Sports with Derivative-Accumulating Self-Ensemble

Han-Jun Choi *, Hyunsung Kim *, Minho Lee, Minchul Jeong, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[ECML PKDD] · 2025년 6월 20일

[실험 결과]

실험 셋팅

✓ 평가 지표

- Position Error (PE): 실제 위치와 예측 위치 간 평균 유클리드 거리 오차
- Step Change Error (SCE): 실제 속도 변화량과 예측 속도 변화량 간 평균 오차

정량적 실험 결과 비교

✓ SOTA 기록 달성: 위치 정확도 및 궤적의 현실성 개선

- 보간 위치 정확도(PE): 기존 SOTA 대비 최대 36.81% 성능 향상
- 보간 현실성 정확도(SCE): 기존 SOTA 대비 약 36.7% 성능 향상

✓ 데이터 효율성 개선: 제한된 데이터로 우수한 성능 확보

- 소량의 데이터에 대해서도 일관성 있는 성능 확인
- 학습 복잡도 개선을 위한 SetTransformer 모델 배치의 타당성 입증


정성적 실험 결과 비교

✓ 물리적 일관성을 갖춘 자연스러운 궤적 예측

- 위치 정확도, 현실성 측면에서 정답 궤적과 가장 비슷하게 예측함을 확인

Table 2: Performance of imputation models on different datasets and scenarios.

Scenario	Metric	Method									
		LI	CS	BRITS	NAOMI	NRTSI	CSDI	GI	IF	IP	MIDAS
Soccer											
Uniform	PE	3.8406	2.2085	7.4859	4.5343	3.1791	3.4295	4.6511	2.0898	1.4563	1.3205
	SCE	0.1299	0.0867	3.9089	3.9793	0.0854	0.1586	0.1191	0.0815	0.1488	0.0516
Agent-wise	PE	5.0752	11.4647	5.7266	—	—	4.0279	5.6011	2.5798	2.0755	1.9832
	SCE	0.1631	0.2939	2.9627	—	—	0.1305	0.1508	0.0976	0.1057	0.0535
Camera	PE	3.1083	1.9209	7.4208	—	—	3.5181	3.6512	2.2151	1.4879	1.2296
	SCE	0.0993	0.0547	4.1967	—	—	0.2132	0.0934	0.3149	0.1554	0.0374
Basketball											
Uniform	PE	3.3481	2.3114	2.9085	1.5254	2.5291	2.2558	2.8305	1.3622	0.9801	0.9727
	SCE	0.1483	0.1025	1.0521	0.3230	0.0734	0.0631	0.1066	0.0531	0.0432	0.0438
Agent-wise	PE	4.4992	10.3857	2.4238	—	—	2.3471	2.5859	1.3345	1.3832	1.3862
	SCE	0.1787	0.2715	0.5397	—	—	0.0563	0.0700	0.0485	0.0373	0.0381
American Football											
Uniform	PE	0.8897	0.7448	1.7990	0.9692	0.5158	0.5558	0.8899	0.3673	0.2073	0.1542
	SCE	1.1063	0.9463	10.9459	2.3112	0.2989	0.4905	1.1023	0.2858	0.1990	0.1126
Agent-wise	PE	1.5128	1.2041	1.7527	—	—	0.6182	1.5128	0.3944	0.2383	0.2104
	SCE	1.0641	0.5306	10.6807	—	—	0.4288	1.0631	0.1869	0.1180	0.0967



1. Work Experience

2. KEY PAPER #1 소개

3. KEY PAPER #2 소개

4. KEY PAPER #3 소개

KEY PAPER #3

Ball trajectory inference from Multi-Agent Sports Contexts Using Set Transformer and Hierarchical Bi-LSTM

Hyunsung Kim, Han-Jun Choi, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[KDD 2023] · 2023년 8월 8일

[연구 요약]

연구 목표

- 축구 경기 자동 중계를 위한 공 궤적 취득 연구
- 선수의 궤적 정보를 활용한 공 궤적 추론 프레임워크 설계

제안 방법


- 경기 내용 전반의 컨텍스트 표현을 위한 임베딩 기법 제안
- 자연스러운 궤적 예측을 위한 물리적 제약 기반 손실 함수 설계
- 도메인 지식 학습을 통한 계층적 공 궤적 추론 구조 설계
- 룰 기반 후처리 알고리즘을 통한 예측 궤적 보정 방법

실험 결과

- 축구 시뮬레이션 데이터셋에 대한 성능 평가
- 기존 SOTA 모델 대비 궤적 예측 정확도 약 25.6% 향상
- 예측 궤적을 활용한 경기 자동 중계, 공 소유권 예측 문제 적용
- 현실 세계의 실용적인 태스크에 적용이 가능함을 입증

성과

- KDD 2023 게재(국제 최우수 학술대회)



Model	PE	RL	PPA	TPA
VRNN	12.3721	0.7206	-	-
Transformer	7.4727	1.2194	-	-
LSTM	5.4667	0.3392	-	-
H-Transformer	4.9136	0.7987	48.91 %	77.91 %
H-Transformer-RL	4.6933	0.5990	49.52 %	78.01 %
H-Transformer-PP	5.4075	0.0021	52.01 %	78.78 %
H-Transformer-RL-PP	5.4093	0.0021	52.18 %	78.66 %
H-LSTM	3.6886	0.1881	64.01 %	85.26 %
H-LSTM-RL	3.6561	0.1391	64.70 %	85.85 %
H-LSTM-PP	4.1285	0.0016	63.84 %	85.34 %
H-LSTM-RL-PP	4.0719	0.0017	64.32 %	85.34 %



KEY PAPER #3

Ball trajectory inference from Multi-Agent Sports Contexts Using Set Transformer and Hierarchical Bi-LSTM

Hyunsung Kim, Han-Jun Choi, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[KDD 2023] · 2023년 8월 8일

[연구 배경]


스포츠 데이터에서 공 궤적 취득 문제

- AI 발전으로 인해 스포츠 분석 분야에서 자동화 기술을 적용하려는 관심 증가
예시) 자동 중계 시스템, 패스 자동 주석 시스템 등
- 모델 학습을 위한 고품질 데이터 수집이 필수적
- 실제 경기 중 연속적인 이동 데이터의 자동 수집이 어려운 실정
- 작고 빠르게 움직이는 공을 정확히 추적하는 것은 매우 어려운 작업

➤ 공의 궤적을 정확하게 취득할 수 있는 모델 필요

기존 연구의 한계점

- 기존 공 궤적 취득 방법: GPS, CV 기반의 방법론 존재
 - GPS 기반: 공 안에 IMU 센서를 삽입
=> 센서 고장, 고비용 문제
 - CV 기반: 컴퓨터 비전 시스템(객체 인식, 추적) 활용
=> Occlusion, miss detection 문제



KEY PAPER #3

Ball trajectory inference from Multi-Agent Sports Contexts Using Set Transformer and Hierarchical Bi-LSTM

Hyunsung Kim, Han-Jun Choi, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[KDD 2023] · 2023년 8월 8일

[제안 방법]

선수 궤적을 활용한 공 궤적 추론 방법



- 공에 비해 선수의 궤적은 상대적으로 취득하기 쉬운 데이터
- **선수의 이동 궤적 정보를 기반으로 공의 위치를 추론하는 방법 제안**
 1. Hierarchical Neural Network
 2. Rule-Based Postprocessing

계층적 구조의 인공 신경망(Hierarchical Neural Network)

- 스포츠 경기의 도메인 특화 지식 학습
 - Step 1: 선수별 공 소유권 확률 예측
 - Step 2: 공 위치 추론(Regression task)

룰 기반 후처리 알고리즘(Rule-Based Postprocessing)

- 신경망 기반 공 위치 예측은 물리적 특성을 따르지 않는 경우 존재
예시) 공이 패스되는 도중 급격히 방향을 바꾸는 문제 등
- 공의 위치 변화는 선수에 의해 터치될 경우에만 발생하도록 후처리 수행
 - 공 소유 확률과 예측된 공 위치를 기반으로 터치·비터치 상황을 구분
 - 터치하지 않은 구간은 패스로 간주 후 선형 보간하여 자연스럽게 연결



(a) Player Possession Classifier.

(b) Ball Trajectory Regressor.

KEY PAPER #3

Ball trajectory inference from Multi-Agent Sports Contexts Using Set Transformer and Hierarchical Bi-LSTM

Hyunsung Kim, Han-Jun Choi, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[KDD 2023] · 2023년 8월 8일

[실험 결과]

실험 셋팅

- 평가 지표
 - Position Error (PE): 실제 위치와 예측 위치 간 평균 거리 오차
 - Reality Loss (RL): 공이 부자연스럽게 방향을 바꾸는 정도
 - Player/Team Possession Accuracy (PPA/TPA): 선수/팀 소유 예측 정확도
- 데이터셋
 - GPS/비디오 기반 축구 경기 데이터

정량적 실험 결과

- ✓ 계층적 구조(Hierarchical structure) 도입 효과
 - H-계열 모델이 비계층 모델 대비 모든 평가지표에서 성능 개선됨을 확인
 - 공 소유 예측을 학습하는 것이 궤적 예측 성능 향상에 기여할 수 있음을 확인
- ✓ Transformer vs LSTM
 - H-LSTM이 H-Transformer 대비 PE 및 RL에서 모두 우수
 - 공 궤적 예측 문제에서는 recurrence 기반 모델인 LSTM이 효과적임을 확인
- ✓ 후처리(Postprocessing) 효과 입증
 - PE는 약간 증가하지만, 물리적 일관성 및 이벤트 인식 정확도 확보

Table 2: Performance of baseline models for ball trajectory and player/team-level ball possession prediction.

Model	PE	RL	PPA	TPA
VRNN	12.3721	0.7206	-	-
Transformer	7.4727	1.2194	-	-
LSTM	5.4667	0.3392	-	-
H-Transformer	4.9136	0.7987	48.91 %	77.91 %
H-Transformer-RL	4.6933	0.5990	49.52 %	78.01 %
H-Transformer-PP	5.4075	0.0021	52.01 %	78.78 %
H-Transformer-RL-PP	5.4093	0.0021	52.18 %	78.66 %
H-LSTM	3.6886	0.1881	64.01 %	85.26 %
H-LSTM-RL	3.6561	0.1391	64.70 %	85.85 %
H-LSTM-PP	4.1285	0.0016	63.84 %	85.34 %
H-LSTM-RL-PP	4.0719	0.0017	64.32 %	85.34 %

KEY PAPER #3

Ball trajectory inference from Multi-Agent Sports Contexts Using Set Transformer and Hierarchical Bi-LSTM

Hyunsung Kim, Han-Jun Choi, Chang-Jo Kim, Jinsung Yoon, Sang-Ki Ko

[KDD 2023] · 2023년 8월 8일

[현실 세계 문제 적용 실험]


축구 경기 자동 분석(Automatic Match Broadcasting)

- 예측된 공 위치를 중심으로 카메라를 이동하여 경기 자동 중계 정확도 확인
- 실제 공 위치(빨간색 점)와 비교했을 때, 추정 정확도가 높은 것을 확인
- 300x300 영역 기준, 약 80% 이상의 정확도로 공을 화면 중앙에 포착

팀 소유권 기반 러닝 지표 분석 정확도

- 공 소유 팀을 추정 후 선수들의 이동 거리 및 고강도 러닝 거리 정확도 비교
- 총 이동 거리 및 고강도 러닝 지표 모두에서 우수한 성능 확인
- 특히, 공격 상황에서 고강도 러닝 거리 추정 오차를 60% 이상 감소

➤ 현실 세계의 다양한 문제에 적용할 수 있음을 확인



Masking	Pass	Passer	Receiver	#. Passes
100 %	0.3877	0.6039	0.5707	0.7935
95 %	0.5972	0.7265	0.7199	0.9031
90 %	0.7428	0.8315	0.8208	0.9347
80 %	0.8693	0.9149	0.8991	0.9331

Method	Total distance		HSR distance	
	Attacking	Defending	Attacking	Defending
Random	0.0881	0.0771	0.5140	0.2091
Ours	0.0360	0.0340	0.2058	0.1251

Figure 6: The estimated and true HSR distance values either when attacking or defending in a test match.

E.O.D